Московский государственный технический университет им. Н. Э. Баумана

Курс «Технологии машинного обучения»

Отчёт по лабораторной работе

Выполнил
Бокатуев М. С.
группа ИУ5-62Б

Проверил:
Гапанюк Ю.Е.

Дата: 04.06.25

Дата:

Подпись:

Подпись:

Москва, 2025 г.

Подготовка данных для работы

In [1]:
```
# imports
import pandas as pd
import numpy as np
import seaborn as sns
from matplotlib import pyplot as plt
from scipy.stats import chi2_contingency
from sklearn.preprocessing import StandardScaler, MinMaxScaler
from sklearn.model_selection import train_test_split
from statsmodels.formula.api import logit
from sklearn import metrics
from sklearn.metrics import classification_report
from sklearn.model_selection import cross_val_score

import graphviz
from sklearn.tree import export_graphviz
from sklearn.tree import DecisionTreeClassifier
from sklearn.model_selection import GridSearchCV
from sklearn.ensemble import RandomForestClassifier

import warnings
from statsmodels.tools.sm_exceptions import ConvergenceWarning
warnings.simplefilter('ignore', ConvergenceWarning)
warnings.simplefilter('ignore', RuntimeWarning)
```

In [4]:
```
names_list_filepath = '/content/names.txt'
attribute_names = []

with open(names_list_filepath, 'r') as file:
    attribute_names = file.read().splitlines()

data = pd.read_csv('/content/spambase.data', names=attribute_names)
data
```

Out[4]:

	word_freq_make	word_freq_address	word_freq_all	word_freq_3d	word_fr
0	0.00	0.64	0.64	0.0	
1	0.21	0.28	0.50	0.0	
2	0.06	0.00	0.71	0.0	
3	0.00	0.00	0.00	0.0	
4	0.00	0.00	0.00	0.0	
...	...	...	...	...	
4596	0.31	0.00	0.62	0.0	
4597	0.00	0.00	0.00	0.0	
4598	0.30	0.00	0.30	0.0	
4599	0.96	0.00	0.00	0.0	
4600	0.00	0.00	0.65	0.0	

4601 rows × 58 columns

Целостность набора данных

Прежде чем анализировать данные, давайте проверим, что атрибут «Класс» содержит только значения 1 и 0. Кроме того, мы проверим наличие значений NaN в наборе данных.

In [ ]:
```
data['Class'].unique()
```

Out[ ]:
```
array([1, 0])
```

In [ ]:
```
count_nan_in_df = data.isnull().sum().sum()
print(f'Number of NaN values: {count_nan_in_df}')
```

```
Number of NaN values: 0
```

Для простоты изменим тип класса на bool и переименуем его в «спам». Следовательно, когда запись имеет spam=True, это означает, что электронное письмо является спамом.

In [ ]:
```
data['spam'] = data['Class'].astype(bool)
data = data.drop(columns=['Class'])
data['spam']
```

Out[ ]:

	spam
0	True
1	True
2	True
3	True
4	True
...	...
4596	False
4597	False
4598	False
4599	False
4600	False

4601 rows × 1 columns

dtype: bool

Изучение общей информации

In [ ]:
```
data.keys()
```

Out[ ]:
```
Index(['word_freq_make', 'word_freq_address', 'word_freq_all', 'word_freq_3
d',
       'word_freq_our', 'word_freq_over', 'word_freq_remove',
       'word_freq_internet', 'word_freq_order', 'word_freq_mail',
       'word_freq_receive', 'word_freq_will', 'word_freq_people',
       'word_freq_report', 'word_freq_addresses', 'word_freq_free',
       'word_freq_business', 'word_freq_email', 'word_freq_you',
       'word_freq_credit', 'word_freq_your', 'word_freq_font', 'word_freq_00
0',
       'word_freq_money', 'word_freq_hp', 'word_freq_hpl', 'word_freq_georg
e',
       'word_freq_650', 'word_freq_lab', 'word_freq_labs', 'word_freq_telne
t',
       'word_freq_857', 'word_freq_data', 'word_freq_415', 'word_freq_85',
       'word_freq_technology', 'word_freq_1999', 'word_freq_parts',
       'word_freq_pm', 'word_freq_direct', 'word_freq_cs', 'word_freq_meetin
g',
       'word_freq_original', 'word_freq_project', 'word_freq_re',
       'word_freq_edu', 'word_freq_table', 'word_freq_conference',
       'char_freq_;', 'char_freq_(', 'char_freq_[', 'char_freq_!',
       'char_freq_$', 'char_freq_#', 'capital_run_length_average',
       'capital_run_length_longest', 'capital_run_length_total', 'spam'],
      dtype='object')
```

In [ ]:
```
class_counts = data['spam'].value_counts()
print(class_counts)
print("\n")
data.info()
```

```
spam
False    2788
True     1813
Name: count, dtype: int64


<class 'pandas.core.frame.DataFrame'>
RangeIndex: 4601 entries, 0 to 4600
Data columns (total 58 columns):
 #   Column                      Non-Null Count  Dtype  
---  ------                      --------------  -----  
 0   word_freq_make              4601 non-null   float64
 1   word_freq_address           4601 non-null   float64
 2   word_freq_all               4601 non-null   float64
 3   word_freq_3d                4601 non-null   float64
 4   word_freq_our               4601 non-null   float64
 5   word_freq_over              4601 non-null   float64
 6   word_freq_remove            4601 non-null   float64
 7   word_freq_internet          4601 non-null   float64
 8   word_freq_order             4601 non-null   float64
 9   word_freq_mail              4601 non-null   float64
 10  word_freq_receive           4601 non-null   float64
 11  word_freq_will              4601 non-null   float64
 12  word_freq_people            4601 non-null   float64
 13  word_freq_report            4601 non-null   float64
 14  word_freq_addresses         4601 non-null   float64
 15  word_freq_free              4601 non-null   float64
 16  word_freq_business          4601 non-null   float64
 17  word_freq_email             4601 non-null   float64
 18  word_freq_you               4601 non-null   float64
 19  word_freq_credit            4601 non-null   float64
 20  word_freq_your              4601 non-null   float64
 21  word_freq_font              4601 non-null   float64
 22  word_freq_000               4601 non-null   float64
 23  word_freq_money             4601 non-null   float64
 24  word_freq_hp                4601 non-null   float64
 25  word_freq_hpl               4601 non-null   float64
 26  word_freq_george            4601 non-null   float64
 27  word_freq_650               4601 non-null   float64
 28  word_freq_lab               4601 non-null   float64
 29  word_freq_labs              4601 non-null   float64
 30  word_freq_telnet            4601 non-null   float64
 31  word_freq_857               4601 non-null   float64
 32  word_freq_data              4601 non-null   float64
 33  word_freq_415               4601 non-null   float64
 34  word_freq_85                4601 non-null   float64
 35  word_freq_technology        4601 non-null   float64
 36  word_freq_1999              4601 non-null   float64
 37  word_freq_parts             4601 non-null   float64
 38  word_freq_pm                4601 non-null   float64
 39  word_freq_direct            4601 non-null   float64
 40  word_freq_cs                4601 non-null   float64
 41  word_freq_meeting           4601 non-null   float64
 42  word_freq_original          4601 non-null   float64
```

```
 43  word_freq_project           4601 non-null   float64
 44  word_freq_re                4601 non-null   float64
 45  word_freq_edu               4601 non-null   float64
 46  word_freq_table             4601 non-null   float64
 47  word_freq_conference        4601 non-null   float64
 48  char_freq_;                 4601 non-null   float64
 49  char_freq_(                 4601 non-null   float64
 50  char_freq_[                 4601 non-null   float64
 51  char_freq_!                 4601 non-null   float64
 52  char_freq_$                 4601 non-null   float64
 53  char_freq_#                 4601 non-null   float64
 54  capital_run_length_average  4601 non-null   float64
 55  capital_run_length_longest  4601 non-null   int64
 56  capital_run_length_total    4601 non-null   int64
 57  spam                        4601 non-null   bool
dtypes: bool(1), float64(55), int64(2)
memory usage: 2.0 MB
```

- **Количество случаев**: 4601, из которых 1813 — СПАМ (39,4%)
- **Количество атрибутов**: 58 (57 непрерывных, 1 категориальный, представляющий метку класса)

Письма можно разделить на две группы: спам и не спам. Чтобы лучше понять эти категории, расчитаем статистику для каждой группы.

In [ ]:
```
spam = data[data['spam'] == True]
non_spam = data[data['spam'] == False]
```

In [ ]:
```
spam.describe()
```

Out[ ]:

	word_freq_make	word_freq_address	word_freq_all	word_freq_3d	word_f
count	1813.000000	1813.000000	1813.000000	1813.000000	1813
mean	0.152339	0.164650	0.403795	0.164672	0
std	0.310645	0.348919	0.480725	2.219087	0
min	0.000000	0.000000	0.000000	0.000000	0
25%	0.000000	0.000000	0.000000	0.000000	0
50%	0.000000	0.000000	0.300000	0.000000	0
75%	0.170000	0.210000	0.640000	0.000000	0
max	4.540000	4.760000	3.700000	42.810000	7

8 rows × 57 columns

In [ ]:
```
non_spam.describe()
```

Out[ ]:

	word_freq_make	word_freq_address	word_freq_all	word_freq_3d	word_f
count	2788.000000	2788.000000	2788.000000	2788.000000	2788
mean	0.073479	0.244466	0.200581	0.000886	0
std	0.297838	1.633223	0.502959	0.021334	0
min	0.000000	0.000000	0.000000	0.000000	0
25%	0.000000	0.000000	0.000000	0.000000	0
50%	0.000000	0.000000	0.000000	0.000000	0
75%	0.000000	0.000000	0.120000	0.000000	0
max	4.340000	14.280000	5.100000	0.870000	10

8 rows × 57 columns

Гистограммы распределения

In [ ]:
```
def plot_histogram(feature, spam, non_spam):
    plt.hist(spam[feature], bins=20, alpha=0.5, label='Spam')
    plt.hist(non_spam[feature], bins=20, alpha=0.5, label='Non-Spam')
    plt.xlabel(feature)
    plt.ylabel('Frequency')
    plt.title(f'Histogram of {feature} for Spam and Non-Spam Emails')
    plt.legend()
    plt.show()
```

In [ ]:
```
plot_histogram('word_freq_business', spam, non_spam)
```

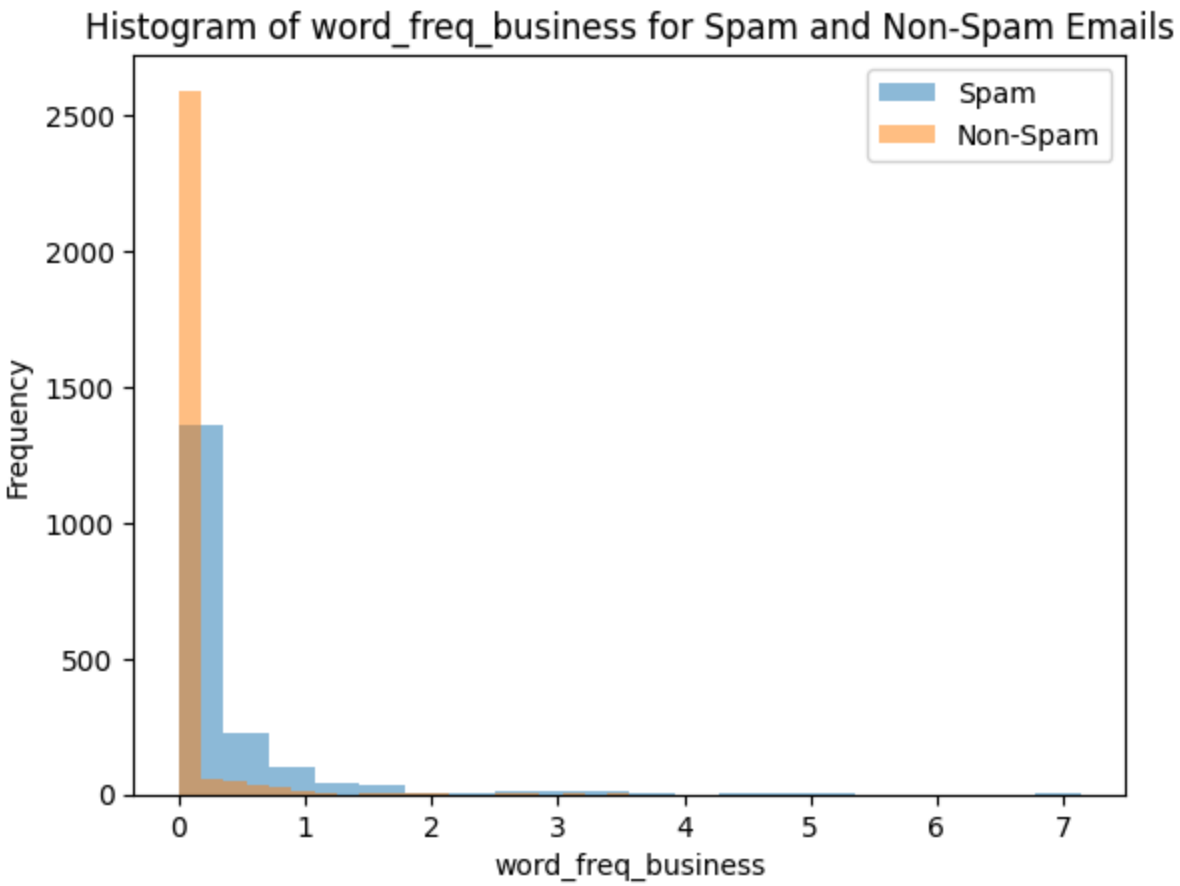

In [ ]:
```
plot_histogram('word_freq_3d', spam, non_spam)
```

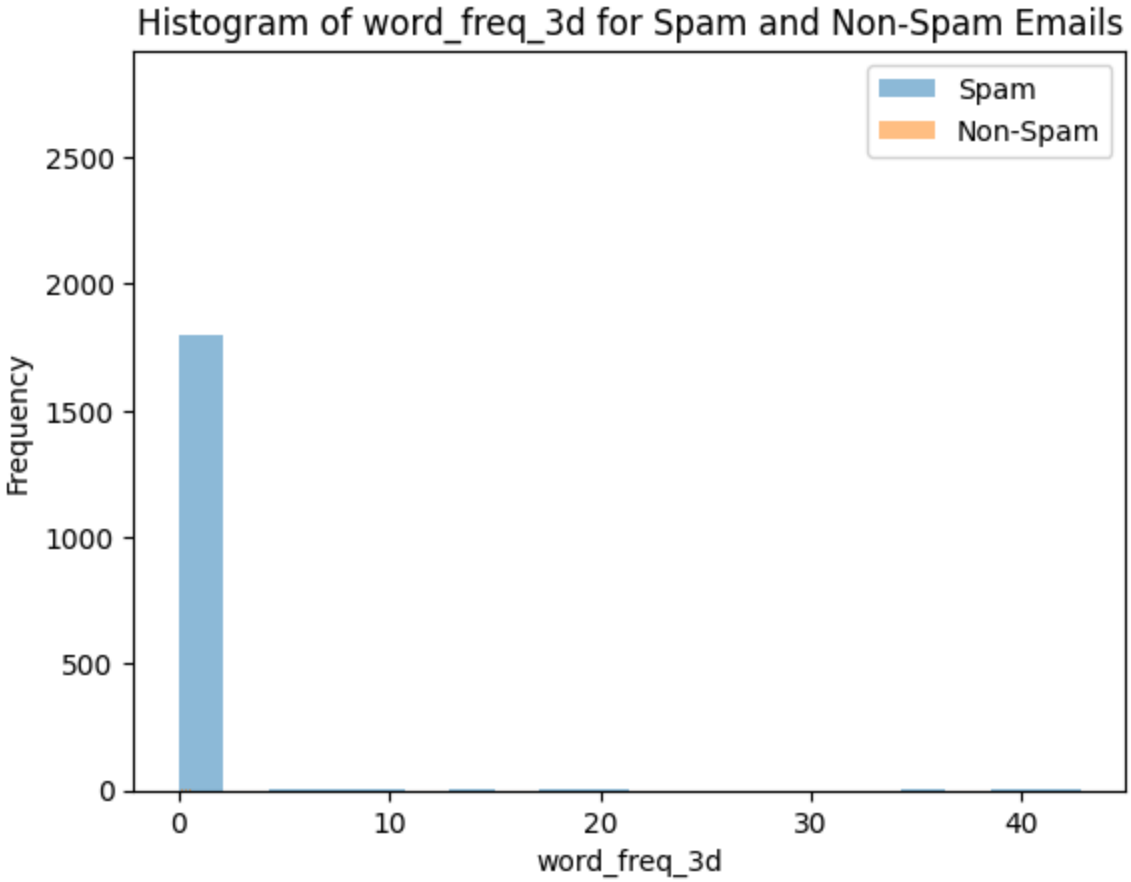

При сравнении word_freq_businessc word_freq_3d становится ясно, что последний является хорошей функцией для различения спама и не спама.

Анализ выбросов

In [ ]:
```
data_wr_fr = data.iloc[:, :-10]
data_char_freq = data.iloc[:, -10:-4]
data_capital_run = data.iloc[:, -4:-1]
def draw_boxplot(ax, label, data):
    ax.boxplot(data,
               vert=True,
               patch_artist=True,
               labels=data.columns)
    ax.set_title(label)
    ax.yaxis.grid(True)
    ax.tick_params(labelrotation=90)

fig, ax = plt.subplots(figsize=(20, 5))
draw_boxplot(ax, 'Boxplots Word Frequencies', data_wr_fr)
plt.show()
```

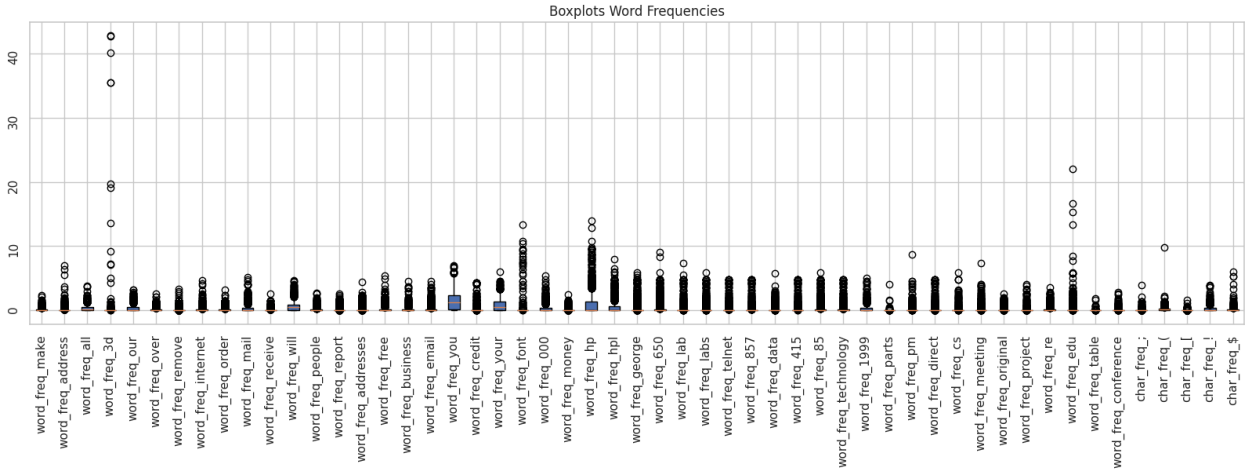

Исследовательский анализ данных

Гипотеза 1: Слова, связанные с коммерческими предложениями, чаще встречаются в спам-письмах.

Усредним значения частот слов и построим их графики.

In [ ]:
```
mean_wf = data.groupby('spam').mean()
mean_wr_fr = mean_wf.iloc[:, 0:-9]
nospam_wr_fr = mean_wr_fr.iloc[0]
spam_wr_fr = mean_wr_fr.iloc[1]
```

In [ ]:
```
plt.figure(figsize=(16, 9))
plt.bar(nospam_wr_fr.index, nospam_wr_fr.values, width=1, alpha=0.8)
plt.bar(spam_wr_fr.index, spam_wr_fr.values, width=1, alpha=0.8)
plt.xticks(rotation='vertical')
plt.legend(['non_spam', 'spam'])
plt.grid()
plt.show()
```

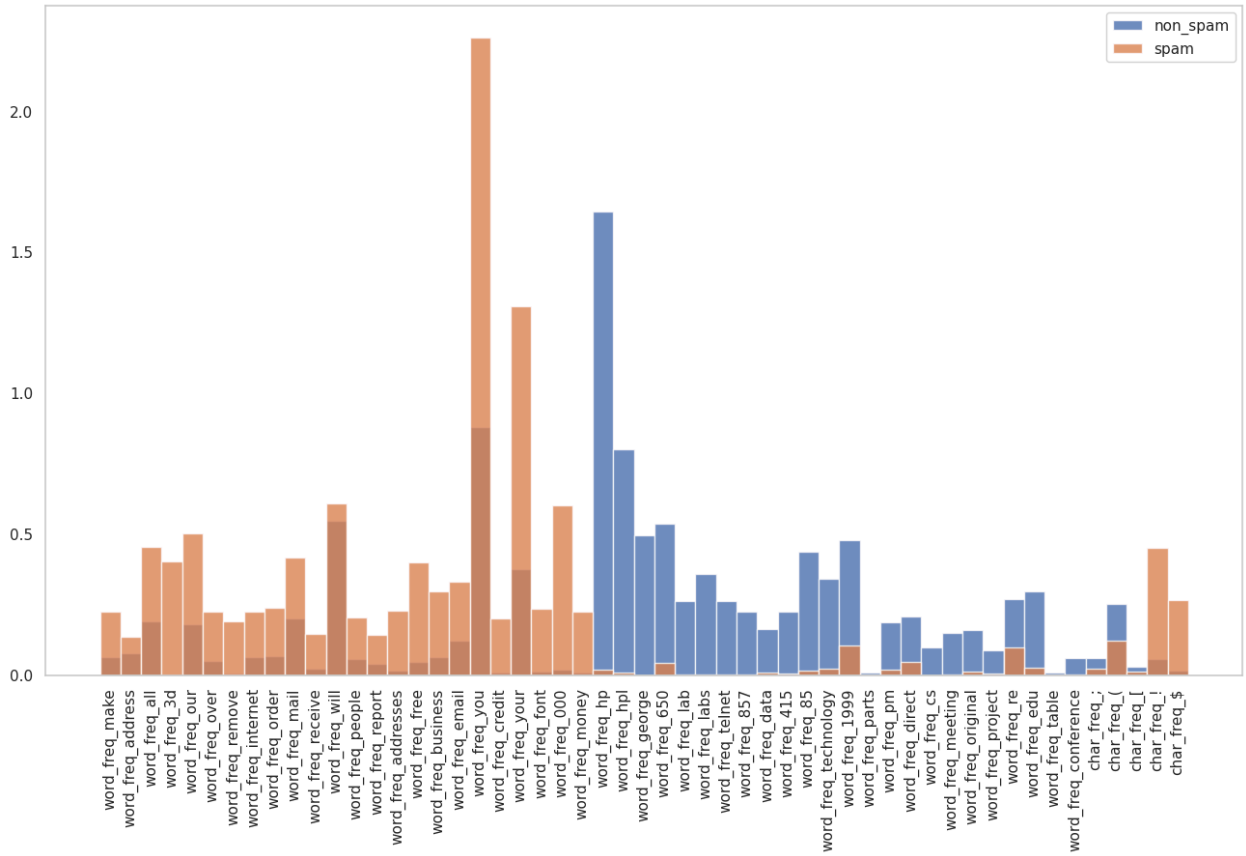

Слова, такие как "free", "win", "money", "order", демонстрируют более высокую среднюю частоту в СПАМ-сообщениях , в то время как другие, такие как "hp", "address", "font" и "george", более распространены в не-спам-сообщениях . Это говорит о том, что слова связанные с коммерческими предложениями чаще встречаются в спам-письмах.

Гипотеза 2: Длина письма: Спам-письма имеют тенденцию быть короче, чем не спам.

In [ ]:
```
from scipy.stats import ttest_ind, mannwhitneyu, shapiro
# Создание дополнительной метрики длины письма
# Сумма частот слов и символов как показатель длины
data['total_word_freq'] = data[[col for col in data.columns if col.startswith(
data['total_char_freq'] = data[[col for col in data.columns if col.startswith(

# Разделение данных на спам и не спам
spam = data[data['spam'] == 1]
non_spam = data[data['spam'] == 0]

# Выбор метрик для анализа длины письма
spam_lengths = spam['capital_run_length_total']
non_spam_lengths = non_spam['capital_run_length_total']

spam_total_word_freq = spam['total_word_freq']
non_spam_total_word_freq = non_spam['total_word_freq']
```

```
spam_total_char_freq = spam['total_char_freq']
non_spam_total_char_freq = non_spam['total_char_freq']


# Визуализация распределения
plt.figure(figsize=(15, 10))

# 'capital_run_length_total'
plt.subplot(3, 1, 1)
sns.kdeplot(spam_lengths, label="Спам", fill=True, color='r')
sns.kdeplot(non_spam_lengths, label="Не спам", fill=True, color='b')
plt.title("Распределение 'capital_run_length_total'")
plt.xlabel("Общее количество заглавных букв")
plt.ylabel("Плотность")
plt.legend()

# 'total_word_freq'
plt.subplot(3, 1, 2)
sns.kdeplot(spam_total_word_freq, label="Спам", fill=True, color='r')
sns.kdeplot(non_spam_total_word_freq, label="Не спам", fill=True, color='b')
plt.title("Распределение 'total_word_freq'")
plt.xlabel("Сумма частот слов")
plt.ylabel("Плотность")
plt.legend()

# 'total_char_freq'
plt.subplot(3, 1, 3)
sns.kdeplot(spam_total_char_freq, label="Спам", fill=True, color='r')
sns.kdeplot(non_spam_total_char_freq, label="Не спам", fill=True, color='b')
plt.title("Распределение 'total_char_freq'")
plt.xlabel("Сумма частот символов")
plt.ylabel("Плотность")
plt.legend()

plt.tight_layout()
plt.show()
```

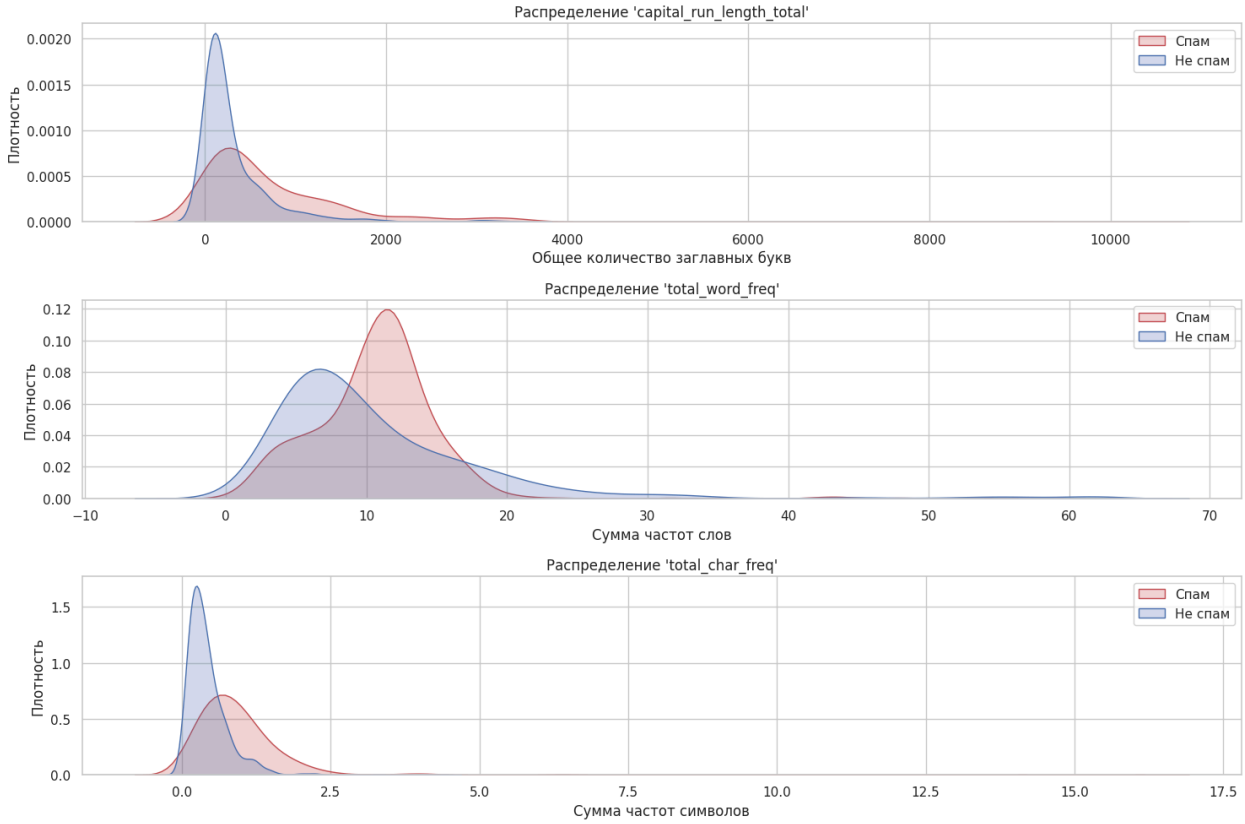

Проверим на нормальность распределения

In [ ]:
```
print("\nПроверка на нормальность распределения для 'capital_run_length_total'
stat_spam, p_spam = shapiro(spam_lengths)
stat_non_spam, p_non_spam = shapiro(non_spam_lengths)
print(f"Спам: p-value = {p_spam}")
print(f"Не спам: p-value = {p_non_spam}")
```

```
Проверка на нормальность распределения для 'capital_run_length_total':
Спам: p-value = 7.577383125428139e-37
Не спам: p-value = 2.2757155672919478e-42
```

Данные не нормально распределены, выполним тест Манна-Уитни:

In [ ]:
```
stat, p_value = mannwhitneyu(spam_lengths, non_spam_lengths)
```

In [ ]:
```
# Результаты теста
print(f"\nРезультаты статистического теста для 'capital_run_length_total': sta
if p_value < 0.05:
    print("Отвергаем гипотезу: длина писем статистически значимо различается."
else:
    print("Не удалось отвергнуть гипотезу: различия в длине писем не статистич
```

```
Результаты статистического теста для 'capital_run_length_total': stat = 51192
8.0, p-value = 1.1870783606124169e-54
Отвергаем гипотезу: длина писем статистически значимо различается.
```

Гипотеза 3: Пунктуация: Спам-письма чаще используют специальные

символы, такие как !, %, $.

In [ ]:
```
# Выбор атрибутов, связанных с пунктуацией
spam_punctuation = spam[['char_freq_!', 'char_freq_$', 'char_freq_#']]
non_spam_punctuation = non_spam[['char_freq_!', 'char_freq_$', 'char_freq_#']]

# Визуализация распределений для пунктуации
plt.figure(figsize=(15, 5))

# char_freq_!
plt.subplot(1, 3, 1)
sns.kdeplot(spam_punctuation['char_freq_!'], label="Спам", fill=True, color='r
sns.kdeplot(non_spam_punctuation['char_freq_!'], label="Не спам", fill=True, c
plt.title("Распределение частоты символа '!'")
plt.xlabel("Частота символа '!'")
plt.ylabel("Плотность")
plt.legend()

# char_freq_$
plt.subplot(1, 3, 2)
sns.kdeplot(spam_punctuation['char_freq_$'], label="Спам", fill=True, color='r
sns.kdeplot(non_spam_punctuation['char_freq_$'], label="Не спам", fill=True, c
plt.title("Распределение частоты символа '$'")
plt.xlabel("Частота символа '$'")
plt.ylabel("Плотность")
plt.legend()

# char_freq_#
plt.subplot(1, 3, 3)
sns.kdeplot(spam_punctuation['char_freq_#'], label="Спам", fill=True, color='r
sns.kdeplot(non_spam_punctuation['char_freq_#'], label="Не спам", fill=True, c
plt.title("Распределение частоты символа '#'")
plt.xlabel("Частота символа '#'")
plt.ylabel("Плотность")
plt.legend()

plt.tight_layout()
plt.show()
```

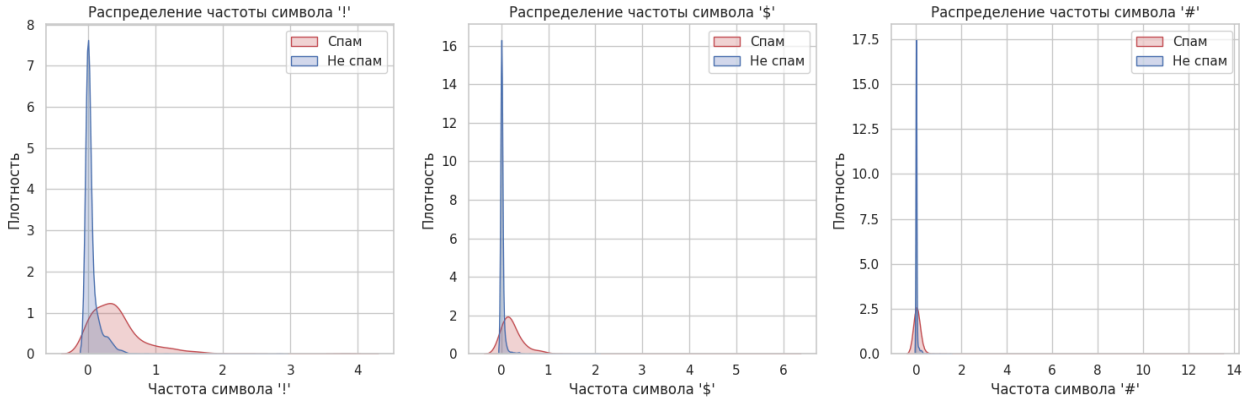

Графики подтверждают гипотезу.

Гипотеза 4: Соотношение цифр и букв: Спам-письма содержат больший процент чисел.

In [ ]:

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from scipy import stats

# Преобразование в числовой формат для столбцов, содержащих частоты символов и
char_columns = ['char_freq_;', 'char_freq_(', 'char_freq_[', 'char_freq_!', 'c
# Столбцы с цифрами (например, содержащие 000, 1999, 415 и т.д.)
digit_columns = [col for col in data.columns if any(digit in col for digit in

# Суммирование частот символов
data['letter_freq'] = data[char_columns].sum(axis=1)

# Суммирование частот цифр
data['digit_freq'] = data[digit_columns].sum(axis=1)

# Рассчитываем соотношение цифр и букв
data['ratio_digits_letters'] = data['digit_freq'] / data['letter_freq']

# Разделение на спам и не спам
spam_data = data[data['spam'] == 1]
non_spam_data = data[data['spam'] == 0]

# Сравнение средних значений соотношения цифр и букв
spam_mean = spam_data['ratio_digits_letters'].mean()
non_spam_mean = non_spam_data['ratio_digits_letters'].mean()


plt.figure(figsize=(12, 6))
sns.boxplot(x='spam', y='ratio_digits_letters', data=data, width=0.6, hue='spa
sns.stripplot(x='spam', y='ratio_digits_letters', data=data, color='black', al
plt.title('Соотношение цифр и букв по категориям (Boxplot с точками)')
plt.xlabel('Категория')
plt.ylabel('Соотношение цифр и букв')
plt.xticks([0, 1], ['Non-Spam', 'Spam'])
plt.legend([], [], frameon=False)  # Убираем лишнюю легенду
plt.show()


plt.figure(figsize=(12, 6))
sns.violinplot(x='spam', y='ratio_digits_letters', data=data, inner="quartile"
sns.stripplot(x='spam', y='ratio_digits_letters', data=data, color='black', al
plt.title('Соотношение цифр и букв по категориям (Violin Plot)')
plt.xlabel('Категория')
plt.ylabel('Соотношение цифр и букв')
plt.xticks([0, 1], ['Non-Spam', 'Spam'])
plt.legend([], [], frameon=False)  # Убираем лишнюю легенду
plt.show()
```

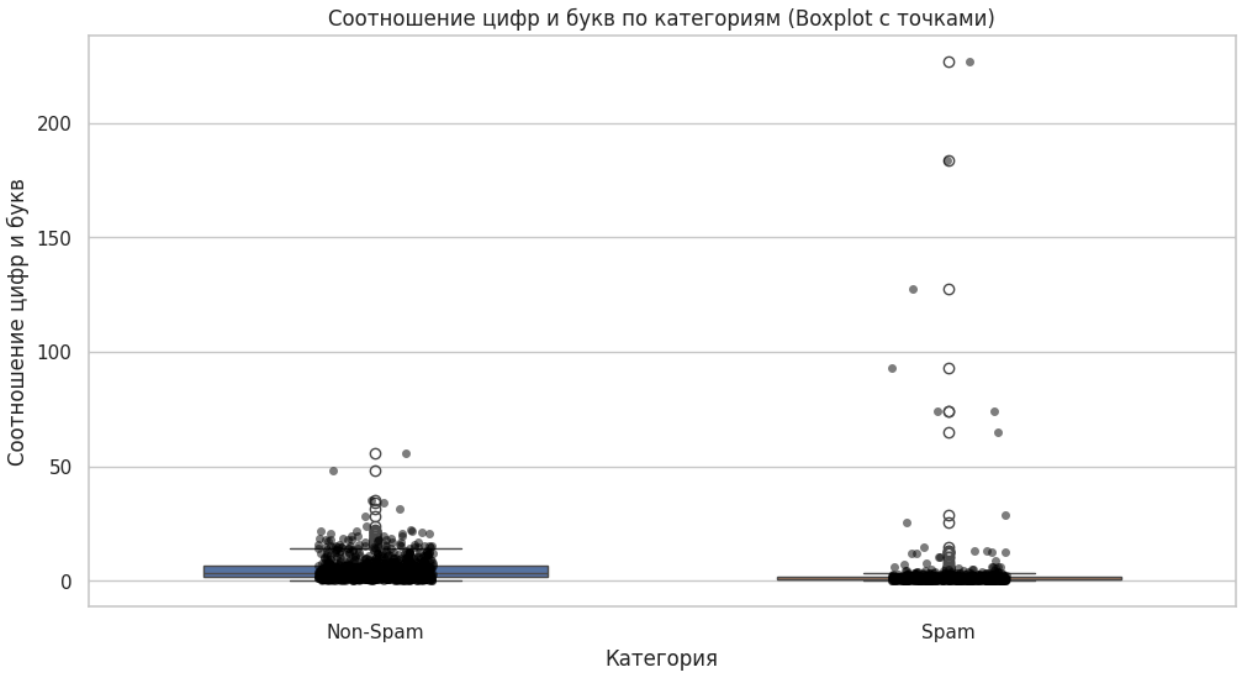

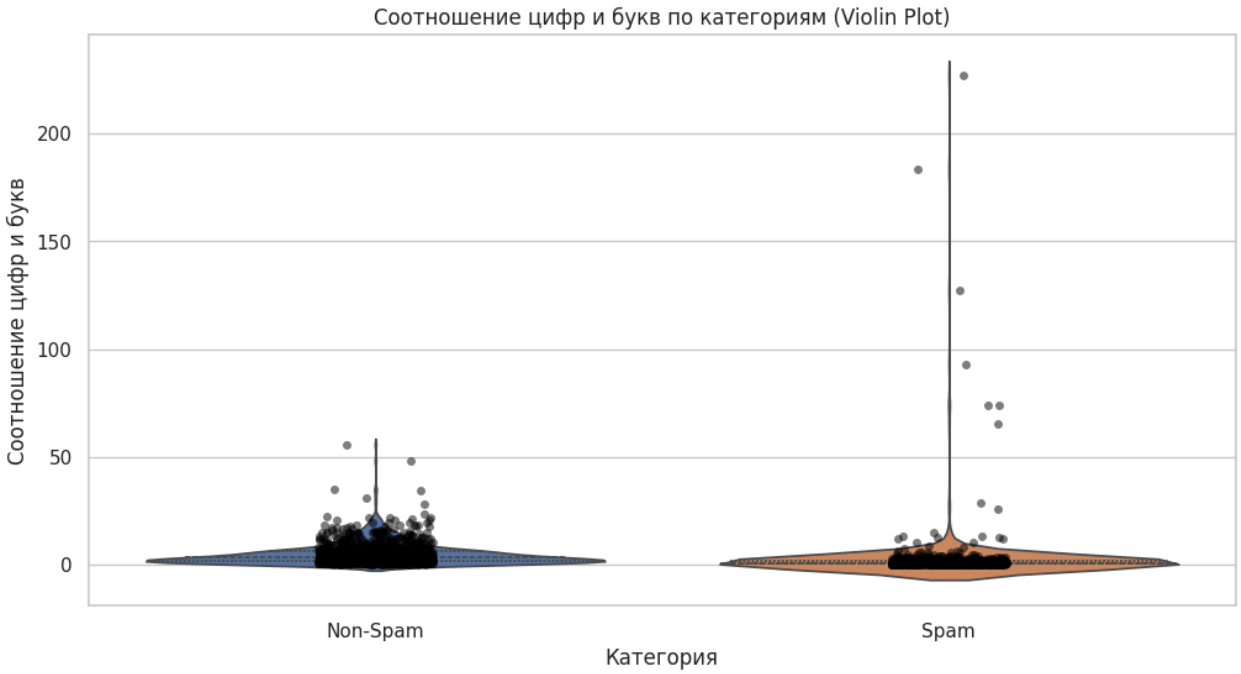

In [ ]:
```
# Фильтруем данные, убирая строки с нулевой частотой букв или цифр
data = data[(data['letter_freq'] != 0) & (data['digit_freq'] != 0)]
data['ratio_digits_letters'] = data['digit_freq'] / data['letter_freq'].replac

# Расчитываем средние значения для спама и не спама
spam_mean = data[data['spam'] == 1]['ratio_digits_letters'].mean()
non_spam_mean = data[data['spam'] == 0]['ratio_digits_letters'].mean()

print(f"Среднее для спама: {spam_mean}, Среднее для не спама: {non_spam_mean}"

# Очищаем данные от NaN и Inf значений
data = data[~data['ratio_digits_letters'].isna()]  # Убираем NaN
```

```
data = data[~data['ratio_digits_letters'].isin([float('inf'), -float('inf')])]

# Отделяем данные для спама и не спама
spam_data = data[data['spam'] == 1]
non_spam_data = data[data['spam'] == 0]

# Проверяем, что в каждой группе есть достаточно данных
if len(spam_data) > 0 and len(non_spam_data) > 0:
    # Выполняем тест Манна-Уитни
    from scipy.stats import mannwhitneyu

    stat, p_value = mannwhitneyu(spam_data['ratio_digits_letters'], non_spam_d
    print(f"U-statistic: {stat}, P-value: {p_value}")
else:
    print("Одна из групп пуста, тест не может быть выполнен.")
```

```
Среднее для спама: 2.4977826210295535, Среднее для не спама: 5.127055079170681
U-statistic: 125889.5, P-value: 9.351208971514821e-116
```

В спам-письмах, в среднем, меньше цифр относительно букв по сравнению с не спам-письмами.P-значение очень маленькое (меньше 0.05), что указывает на то, что разница между группами статистически значима. **Гипотеза неверна**.

Гипотеза 5: Заглавные буквы: Спам-письма чаще используют заглавные буквы для привлечения внимания.

In [ ]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import mannwhitneyu

# 1. Загрузка данных (если еще не загружено)
# data = pd.read_csv('spambase.csv')

# 2. Рассчитываем среднее для спама и не спама для каждого признака
spam_capital_avg = data[data['spam'] == 1]['capital_run_length_average'].mean(
non_spam_capital_avg = data[data['spam'] == 0]['capital_run_length_average'].m

spam_capital_longest = data[data['spam'] == 1]['capital_run_length_longest'].m
non_spam_capital_longest = data[data['spam'] == 0]['capital_run_length_longest

spam_capital_total = data[data['spam'] == 1]['capital_run_length_total'].mean(
non_spam_capital_total = data[data['spam'] == 0]['capital_run_length_total'].m

print(f"Средняя длина последовательности заглавных букв для спама: {spam_capit
print(f"Средняя длина последовательности заглавных букв для не спама: {non_spa
print(f"Максимальная длина последовательности заглавных букв для спама: {spam_
print(f"Максимальная длина последовательности заглавных букв для не спама: {no
print(f"Общая длина всех последовательностей заглавных букв для спама: {spam_c
print(f"Общая длина всех последовательностей заглавных букв для не спама: {nor
```

```
# 5. Визуализация данных
# Устанавливаем стиль графиков
sns.set(style="whitegrid")

# Гистограммы для каждого признака
fig, axes = plt.subplots(1, 3, figsize=(18, 6))

# Гистограмма для 'capital_run_length_average'
sns.histplot(spam_data['capital_run_length_average'], color='red', kde=True, l
sns.histplot(non_spam_data['capital_run_length_average'], color='blue', kde=Tr
axes[0].set_title('Средняя длина последовательности заглавных букв')
axes[0].legend()

# Гистограмма для 'capital_run_length_longest'
sns.histplot(spam_data['capital_run_length_longest'], color='red', kde=True, l
sns.histplot(non_spam_data['capital_run_length_longest'], color='blue', kde=Tr
axes[1].set_title('Максимальная длина последовательности заглавных букв')
axes[1].legend()

# Гистограмма для 'capital_run_length_total'
sns.histplot(spam_data['capital_run_length_total'], color='red', kde=True, lab
sns.histplot(non_spam_data['capital_run_length_total'], color='blue', kde=True
axes[2].set_title('Общая длина последовательностей заглавных букв')
axes[2].legend()

plt.tight_layout()
plt.show()
```

```
Средняя длина последовательности заглавных букв для спама: 7.678766216216217
Средняя длина последовательности заглавных букв для не спама: 2.902649323621228
Максимальная длина последовательности заглавных букв для спама: 152.82162162162
163
Максимальная длина последовательности заглавных букв для не спама: 29.758584807
492195
Общая длина всех последовательностей заглавных букв для спама: 774.605405405405
3
Общая длина всех последовательностей заглавных букв для не спама: 326.462018730
4891
```

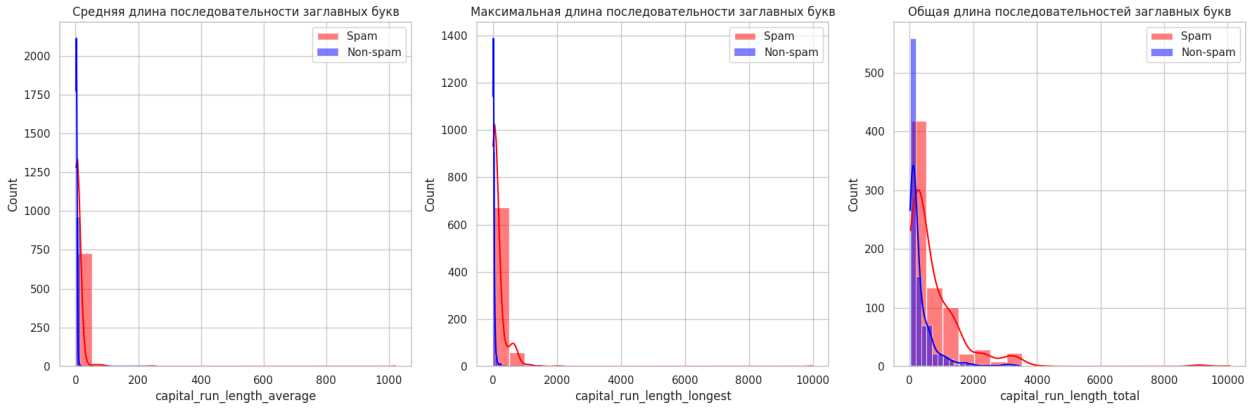

В целом, все три признака (средняя длина, максимальная длина и общая

длина последовательностей заглавных букв) показывают существенные различия между спамом и не спамом. Это подтверждает вашу гипотезу.

Анализ корреляции

In [ ]:
```
new_df = data.iloc[:, :-1].copy()

plt.rcParams.update({'figure.figsize':(60,55), 'figure.dpi':100})

correlation_matrix = new_df.corr(method='spearman')
sns.heatmap(correlation_matrix, annot=True, fmt=".2f", vmin=-1, vmax=1, cbar=T
plt.show()
```

Output hidden; open in https://colab.research.google.com to view.

In [ ]:
```
threshold = 0.7
high_corr = correlation_matrix[abs(correlation_matrix) > threshold]
np.fill_diagonal(high_corr.values, np.nan)
mask = np.triu(np.ones_like(high_corr, dtype=bool))
inverse_mask = ~mask

high_corr_masked = high_corr * inverse_mask
high_corr_masked.dropna(how='all', axis=1, inplace=True)
high_corr_masked.dropna(how='all', axis=0, inplace=True)

mask = np.triu(np.ones_like(high_corr_masked, dtype=bool))

plt.rcParams.update({'figure.figsize':(15,11), 'figure.dpi':100})

sns.heatmap(high_corr_masked, mask=mask, annot=True, fmt=".2f", vmin=-1, vmax=
plt.show()
```

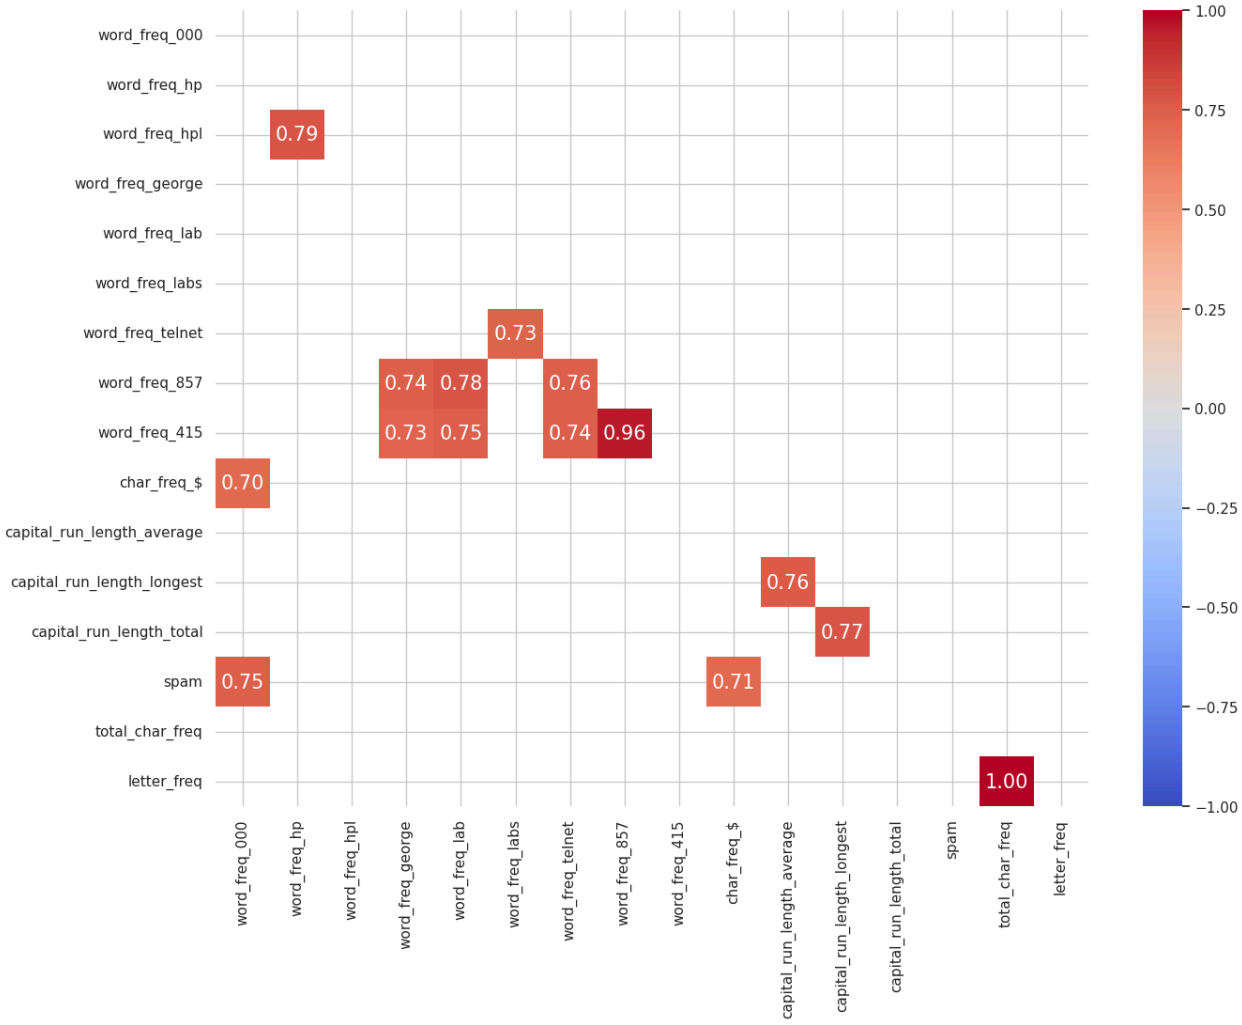

- **word_freq_415 и char_freq_$**: Очень сильная положительная корреляция (0,96) говорит о том, что эти два признака тесно связаны. Увеличение одного из них, скорее всего, соответствует увеличению другого.
- **word_freq_415 и word_freq_857**: Еще одна сильная положительная корреляция (0,75) говорит о том, что эти признаки также сильно связаны.
- **word_freq_415` и word_freq_telnet**: Сильная корреляция (0,74) указывает на то, что эти признаки, как правило, меняются в одном направлении.
- **word_freq_857 и word_freq_telnet**: Высокая корреляция (0,78) говорит о том, что эти признаки также тесно связаны.
- **capital_run_length_longest и capital_run_length_total**: Сильная корреляция (0,77) указывает на то, что эти признаки имеют тесную линейную связь.
- **spam и total_char_freq**: Сильная корреляция (0,75) означает, что

количество символов в сообщении является важным фактором при определении того, является ли оно спамом.

- **word_freq_857` и word_freq_415**: Умеренная корреляция (0,73) говорит о том, что эти признаки изменяются в одном направлении, но с более слабой связью по сравнению с более сильными корреляциями.
- **capital_run_length_average и capital_run_length_total**: Умеренная корреляция (0,76) указывает на то, что эти признаки также показывают линейную зависимость, хотя и не такую сильную, как предыдущие два.